

گزارش کامل تمرین 1

سارا محمدی

پیاده‌سازی روی مجموعه داده Boston Housing با دو ویژگی RM و LSTAT

هدف تمرین

در این تمرین یک مدل خطی مبتنی بر ساختار پرسپترون از ابتدا پیاده‌سازی می‌شود تا مقدار MEDV، یعنی ارزش میانه خانه‌ها، بر اساس دو ویژگی RM و LSTAT پیش‌بینی شود. داده‌ها به بخش آموزش و آزمون تقسیم می‌شوند، ویژگی‌ها و متغیر هدف استانداردسازی می‌شوند و پارامترهای مدل با گرادینت کاهشی به‌روزرسانی می‌گردند.

انتخاب ویژگی‌ها

ویژگی RM میانگین تعداد اتاق‌های هر واحد مسکونی است و معمولاً رابطه‌ای مستقیم با قیمت دارد. ویژگی LSTAT درصد جمعیت با وضعیت اجتماعی-اقتصادی پایین‌تر را نشان می‌دهد و غالباً با قیمت رابطه معکوس دارد. این دو ویژگی از نظر تفسیری معنادارند و برای نمایش یک صفحه رگرسیون سه‌بعدی نیز مناسب هستند.

روند انجام کار

۱) بارگذاری کتابخانه‌ها و تثبیت بذر تصادفی

۲) دریافت داده و تشکیل DataFrame

۳) انتخاب ویژگی‌ها و تفکیک آموزش/آزمون

۴) استانداردسازی

۵) تعریف مدل و تابع آموزش

۶) ارزیابی با MSE و R^2

۷) بررسی روند خطا

۸) رسم صفحه پیش‌بینی سه‌بعدی.

۱. وارد کردن کتابخانه‌ها

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

from sklearn.datasets import fetch_openml
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import mean_squared_error, r2_score

np.random.seed(0)
```

کتابخانه‌های محاسبات عددی، مدیریت داده، ترسیم و ابزارهای ارزیابی فراخوانی شده‌اند. مقدار بذر تصادفی باعث تکرارپذیری نتیجه می‌شود.

۲. دریافت و مشاهده داده‌ها

```
boston = fetch_openml(name='boston', version=1, as_frame=True)
df = boston.data.copy()
df['MEDV'] = boston.target.astype(float)
df.head()
```

مجموعه داده Boston از OpenML دریافت شده و ستون MEDV به عنوان هدف به جدول افزوده شده است. پنج ردیف نخست برای کنترل ساختار داده نمایش داده می‌شود.

نمونه داده خروجی

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	\
0	0.00632	18.0	2.31	0	0.538	6.575	65.2	4.0900	1	296.0	15.3	
1	0.02731	0.0	7.07	0	0.469	6.421	78.9	4.9671	2	242.0	17.8	
2	0.02729	0.0	7.07	0	0.469	7.185	61.1	4.9671	2	242.0	17.8	
3	0.03237	0.0	2.18	0	0.458	6.998	45.8	6.0622	3	222.0	18.7	
4	0.06905	0.0	2.18	0	0.458	7.147	54.2	6.0622	3	222.0	18.7	
	B	LSTAT	MEDV									
0	396.90	4.98	24.0									
1	396.90	9.14	21.6									
2	392.83	4.03	34.7									
3	394.63	2.94	33.4									
4	396.90	5.33	36.2									

پنج ردیف نخست شامل ویژگی‌هایی مانند CRIM، RM، AGE، LSTAT و مقدار هدف MEDV است. برای نمونه، در ردیف اول RM برابر 6.575، LSTAT برابر 4.98 و MEDV برابر 24.0 است.

۳. انتخاب ویژگی‌ها و تقسیم داده‌ها

```
x = df[['RM', 'LSTAT']].values
y = df['MEDV'].values.reshape(-1, 1)

x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.2, random_state=0)
```

دو ستون RM و LSTAT به‌عنوان ورودی انتخاب شده‌اند. ۸۰ درصد داده‌ها برای آموزش و ۲۰ درصد برای آزمون کنار گذاشته می‌شوند.

۴. استانداردسازی داده‌های آموزش و آزمون

```
sx = StandardScaler()
sy = StandardScaler()

x_train_n = sx.fit_transform(x_train)
x_test_n = sx.transform(x_test)
y_train_n = sy.fit_transform(y_train)
```

برای پایدار شدن آموزش گرادیانی، ورودی‌ها و هدف بر اساس آمار بخش آموزش استاندارد می‌شوند. داده آزمون فقط با تبدیل آموخته‌شده از آموزش مقیاس‌بندی می‌شود.

۵. تعریف مدل پرسپترون رگرسیونی

```
class Perceptron:
    def __init__(self, lr=0.05, epochs=500):
        self.lr = lr
        self.epochs = epochs

    def fit(self, X, y):
        n, m = X.shape
        self.w = np.zeros((m, 1))
        self.b = 0.0
        self.losses = []

        for i in range(self.epochs):
            y_pred = X @ self.w + self.b
            error = y_pred - y

            dw = (2 / n) * X.T @ error
            db = (2 / n) * np.sum(error)

            self.w -= self.lr * dw
            self.b -= self.lr * db

            self.losses.append(np.mean(error ** 2))

    def predict(self, X):
        return X @ self.w + self.b
```

مدل دارای دو وزن و یک بایاس است. در هر دوره، پیش‌بینی، خطا، گرادیان وزن‌ها و گرادیان بایاس محاسبه می‌شود و میانگین مربعات خطا ذخیره می‌گردد.

۶. آموزش مدل، پیش‌بینی و ارزیابی

```
model = Perceptron(lr=0.05, epochs=500)
model.fit(X_train_n, y_train_n)

y_pred_n = model.predict(X_test_n)
y_pred = sy.inverse_transform(y_pred_n)

print('MSE:', mean_squared_error(y_test, y_pred))
print('R2:', r2_score(y_test, y_pred))
```

مدل طی ۵۰۰ دوره آموزش می‌بیند. سپس پیش‌بینی‌ها به مقیاس اصلی قیمت برگردانده شده و با دو معیار MSE و R^2 سنجیده می‌شوند.


```
MSE: 37.3831056380951
R2: 0.5409084827270523
```

ضریب تعیین نشان می‌دهد مدل با استفاده از همین دو ویژگی حدود ۵۴ درصد تغییرات قیمت در داده‌های آزمون را توضیح می‌دهد. مقدار MSE نیز میانگین مربع فاصله پیش‌بینی‌ها از مقادیر واقعی را در مقیاس اصلی MEDV بیان می‌کند.

۷. بررسی کاهش خطا در طول آموزش

```
plt.plot(model.losses)
plt.xlabel('Epoch')
plt.ylabel('Loss (MSE)')
plt.title('The process of reducing errors during training')
plt.show()
```

نمودار خطا نشان می‌دهد تابع هزینه در دوره‌های ابتدایی با سرعت کاهش یافته و سپس به مقدار پایدار نزدیک می‌شود؛ این رفتار نشانه همگرایی آموزش است.




۸. ترسیم صفحه پیش‌بینی سه‌بعدی

```
rm_range = np.linspace(X[:, 0].min(), X[:, 0].max(), 50)
lstat_range = np.linspace(X[:, 1].min(), X[:, 1].max(), 50)
RM, LSTAT = np.meshgrid(rm_range, lstat_range)

grid = np.column_stack([RM.ravel(), LSTAT.ravel()])
grid_n = sx.transform(grid)
pred_n = model.predict(grid_n)
Y_PRED = sy.inverse_transform(pred_n).reshape(RM.shape)

fig = plt.figure(figsize=(10, 7))
ax = fig.add_subplot(projection='3d')
ax.scatter(X_test[:, 0], X_test[:, 1], y_test.ravel(), color='blue', label='real data')
ax.plot_surface(RM, LSTAT, Y_PRED, alpha=0.5, cmap='autumn')
ax.set_xlabel('RM')
ax.set_ylabel('LSTAT')
ax.set_zlabel('MEDV')
ax.legend()
plt.show()
```

نقاط آبی داده‌های واقعی آزمون و سطح رنگی پیش‌بینی مدل را نشان می‌دهند. چون مدل خطی است، خروجی یک صفحه در فضای RM، LSTAT و MEDV خواهد بود.



جمع بندی

مدل پیاده سازی شده بدون استفاده از رگرسیون آماده کتابخانه، رابطه خطی بین دو ویژگی RM و LSTAT و قیمت MEDV را آموخت. کاهش منظم خطا، همگرایی فرایند آموزش را تأیید می کند. مقدار R^2 برابر با 0.5409 نشان می دهد دو ویژگی انتخابی بخش مهمی از تغییرات قیمت را توضیح می دهند، اما برای افزایش دقت می توان ویژگی های بیشتری افزود، نرخ یادگیری و تعداد دوره ها را تنظیم کرد یا از مدل های غیرخطی استفاده نمود.

با افزایش RM، مقدار پیش بینی شده MEDV افزایش می یابد و با افزایش LSTAT کاهش پیدا می کند. فاصله برخی نقاط واقعی از سطح پیش بینی نیز محدودیت مدل خطی دو ویژگی را آشکار می سازد.